

Previsao de Consumo Energetico

Desafio Tecnico - Cientista de Dados Pleno

Solucao preditiva para consumo energetico residencial

Contexto e Objetivo

Contexto

- Dados de 100 clientes residenciais ao longo de 180 dias (Jan-Jun 2023)
- Dados climaticos de 5 regioes (temperatura e umidade)
- Desafio: estimar o consumo energetico futuro dos clientes

Objetivo

- Construir modelo preditivo para consumo energetico diario
- Identificar fatores que influenciam o consumo
- Criar pipeline reproduzivel e escalavel

Dados Disponveis

Datasets

- consumo.csv: 18.000 registros (100 clientes x 180 dias)
- clima.csv: 900 registros (5 regioes x 180 dias) - 45 temperaturas ausentes
- clientes.csv: 100 clientes - 5 com regioao 'Desconhecida'

Tratamento Realizado

- Regioes 'Desconhecida': atribuidas por similaridade de consumo
- Temperaturas ausentes: interpolacao linear por regioao
- Tabelas normalizadas criadas no DuckDB

Feature Engineering

Features Temporais

- Mes, dia da semana, dia do mes, semana do ano, flag weekend

Features de Lag (autoregressivas)

- Consumo dos ultimos 1, 2, 3 e 7 dias
- Medias moveis de 7, 14 e 30 dias
- Desvio padrao movel de 7 dias
- Min/Max movel de 7 dias

Features Climaticas

- Temperatura e umidade do dia
- Temperatura do dia anterior (lag)
- Regiao codificada (Label Encoding)

Modelagem

Modelos Treinados

- Random Forest Regressor (200 arvores, max_depth=15)
- LightGBM Regressor (300 iteracoes, learning_rate=0.05)

Validacao Temporal

- Split temporal: treino Jan-Mai / teste Jun
- Expanding window cross-validation (Mar a Jun)
- Evita data leakage temporal

Registro de Modelos

- MLflow para tracking de experimentos
- Pickle versionado para deploy

Resultados - Metricas no Teste

Metrica	Random Forest	LightGBM
MAE (kWh)	1.8620	1.8607
RMSE (kWh)	2.3308	2.3257
R2	0.6117	0.6134
MAPE (%)	13.91	13.81

Melhor modelo: LightGBM

Principais Insights

Features Mais Importantes

- Lags de consumo (1 e 7 dias) são os preditores mais fortes
- Médias móveis capturam tendências de médio prazo
- Variáveis climáticas têm impacto secundário

Padrões Identificados

- Consumo varia sazonalmente (verão -> inverno)
- Padrões semanais presentes (dias úteis vs fim de semana)
- Regiões apresentam níveis de consumo distintos

Qualidade dos Dados

- 5% das temperaturas ausentes (tratadas por interpolação)
- 5 clientes com região incorreta (corrigidos por similaridade)

Pipeline e Arquitetura

Pipeline Reprodutivel (src/pipeline.py)

- Etapa 1: Ingestao dos CSVs
- Etapa 2: Transformacoes (limpeza, DuckDB, feature engineering SQL)
- Etapa 3: Treinamento (RF + LightGBM com MLflow)
- Etapa 4: Inferencia (previsoes com melhor modelo)

Tecnologias Utilizadas

- Python (Pandas, Scikit-learn, LightGBM)
- DuckDB + SQL para feature engineering
- MLflow para tracking de experimentos
- Plotly para dashboard interativo
- Git para versionamento

Proximos Passos

Melhorias no Modelo

- Hyperparameter tuning com Optuna/Bayesian Search
- Modelos de series temporais (Prophet, LSTM)
- Ensemble dos modelos (stacking)

Engenharia

- Containerizacao com Docker
- CI/CD para retreinamento automatico
- Monitoramento de drift de dados e modelo

Dados

- Incorporar dados de feriados e eventos
- Dados de tarifa energetica
- Dados socioeconomicos por regioao

Obrigado!